Esercitazioni di Calcolo Parallelo

Paolo Avogadro

DISCo, Università di Milano-Bicocca U14, Id&aLab T36 paolo.avogadro@unimib.it Aula Lezione T014, edificio U14

- Martedi' 15:30-17:30
- Mercoledi' 10:30-12:30

Paolo Avogadro (DISCo) Milano 2019

1/54

Intro: openMP



- openMP = open specifications for Multi Processing
- openMP standard nato nel 1997 per il FORTRAN e portato poi a C/C++
- openMP e' una API per ambienti multi-thread memory sharing
- openMP definisce:
 - direttive per il compilatore
 - una libreria di funzioni a runtime
 - variabili d'ambiente
- per la gioia di grandi e piccini, openMP e' uno standard non una implementazione, per questo le implementazioni (per esempio GNU e Intel) possono avere dei comportamenti differenti.
- openMP lascia al programmatore il controllo dell'esistenza di deadlock e comportamenti non-deterministici
- openMP non definisce particolari standard di I/O

Un sito di riferimento: https://computing.llnl.gov/tutorials/openMP/#PRIVATE

da MPI a openMPI



Visto che abbiamo un'idea di cosa sia MPI, ha senso prendere questo standard come paragone per poter capire cosa sia openMP

- Grossolanamente parlando l'idea dove nasce e': MPI ↔ NUMA (Non Uniform Memory Access) le singole cpu accedono solo alla propria area di memoria
- con la medesima grossolanita': openMP ↔ UMA (Uniform Memory Access) tutte le cpu hanno accesso ad una area di memoria condivisa

In realta' le topologie delle memorie sono complicate e, su una macchina NUMA, un core puo' accedere alla memoria privilegiata di un altro core con costo di latenza (non e' quindi piu' UMA ma openMP funge, perche' i processi accedono alla stessa memoria RAM (o anche cache in alcuni casi) solo con tempi diversi.

Nel caso di MPI, non esistendo una memoria condivisa, si deve definire un protocollo di comunicazione tra processi. openMP viene invece pensato per un ambiente dove la **comunicazione** tra varie unita' di calcolo avviene accedendo alla memoria condivisa, servono quindi dei protocolli per definire questi accessi.

- ricordiamo che MPI si basa (prevalentemente) su una logica SPMD (un solo codice gira ed elabora dati differenti)
- anche openMP segue il paradigma SPMD in cui pero' e' essenziale il concetto di work sharing in cui i singoli thread eseguono parti differenti del lavoro.

Un paragone introduttivo tra MPI e openMP:

MPI

tante CPU girano sempre
i processi necessitano di un protocollo per comunicare
il codice va progettato parallelo

openMP

utilizzo CPU solo alla bisogna i thread accedono alla stessa memoria parallelizzazione progressiva

Cos'e' un thread? (differenze rispetto ad un processo)



- (ricordi di MPI...) un processo e' un'istanza di esecuzione del programma (ergo: un processo fa girare tutto un codice)
- un thread (o instruction stream) e' la piu' piccola unita' di calcolo che puo' essere gestita dal sistema (un thread spesso fa girare solo una piccola parte di un codice)
- in alcune parti di un processo possono girare vari thread (non e' vero il contrario)
- i thread di un processo possono condividere la memoria assegnata al processo.
- invece processi differenti, in genere, non condividono* le risorse.

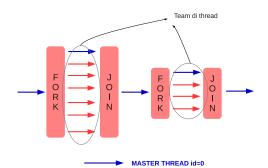
*in realta' alcune risorse possono essere condivise tra processi differenti, per esempio la memoria di massa.



L'idea di openMP e' che:

introduzione ad openMP

- il codice gira su una macchina con molte "cpu/core" con memoria condivisa
- la parte seriale di codice non ha senso che venga fatta girare su tutte le cpu! (economia)
- esiste un master thread che fa girare il codice
- al momento della bisogna (per esempio quando c'e' un ciclo for che puo' beneficiare della parallelizzazione) si inserisce l'apposito costrutto di openMP.
- a questo punto c'e'un fork: dal master thread si crea un team di thread che eseguono il calcolo parallelo (in realta' si ha
 concurrency, o potenziale parallelismo).
- alla fine della sessione parallela tutti i thread tranne il master cessano di esistere e il calcolo riprende in modo seriale, questo viene chiamato una: join (dove vi e' una barriera implicita).



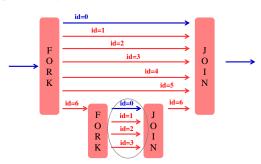
Fork: parallelismo innestato



- E' possibile fare creare un nuovo team da un thread di una regione parallela
- Attenzione pero': questo comportamento di default e' Spento (non avviene nessun fork se si chiama un costrutto parallelo in un costrutto parallelo).
- per accendere il nested parallelism si puo' settare una variabile d'ambiente: OMP_NESTED = true
- oppure usare la seguente funzione a runtime: omp_set_nested(1)

Nested Parallelism

MASTER THREAD id=0



termini



- parallel region: parte di codice dove puo' agire piu' di un thread
- una regione parallela e' considerata attiva se vi agisce piu' di un thread (se c'e' solo il thread master, la regione non e' attiva.
- a tutti i thread viene assegnato un numero intero di identificazione progressivo chiamato id (e' il cugino del rank di MPI)
- il master thread ha id=0
- tutti i comandi (statement) in una regione parallela sono eseguiti da tutti i thread nella regione parallela
- quando tutti i thread hanno completato il loro compito si arriva alla fine della regione parallela: c'e' un JOIN.
- tutti i thread tranne il master cessano di esistere.

Per compilare e fare girare un codice



- Per un codice in C serve un header iniziale: #include <omp.h>
- e' possibile (NON NECESSARIO), definire delle variabili d'ambiente, che contengano, per esempio il numero di thread che si vuole fare "creare" di default al momento dei fork.
- al momento della compilazione con gcc si deve usare la flag: -fopenmp, per esempio: gcc -fopenmp miocodice.c -o miocodice.x
- per il compilatore icc: icc -qopenmp miocodice.c -o miocodice.x
- ullet la flag con il compilatore pg e': pgcc -mp miocodice.c -o miocodice.x
- il codice ottenuto, viene poi lanciato semplicemente con ./miocodice.x (non si ha una modalita' di lancio particolare, come invece c'era in MPI).

Ciao Mondo!



Il primo codice openMP:

- # pragma omp sta per pragmatic information del tipo openMP e serve al compilatore che, nel momento della compilazione, sa di dover fare qualcosa (descritto nel seguito della "frase").
- la direttiva parallel dice al compilatore di fare un FORK e creare un team di thread (in questo caso, la clausola (clause) num_threads (5) definisce che i thread di questa regione parallela devono essere 5).
- Ci possono essere comandi #pragma diversi da quelli omp, in altri ambiti.
- Occhio: se si apre la parentesi graffa che definisce il costrutto parallelo sulla stessa linea di #pragma omp parallel
 si ottiene un errore
- Altro occhio: se si dimentica di usare la clausola parallel, il fork non avviene e c'e' solo il master thread.

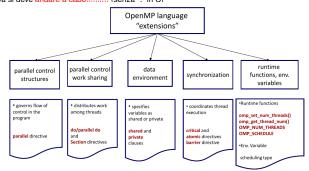
Le direttive



- i comandi sono CasE sensitivE (in C)
- si puo' specificare un solo nome della direttiva (p.es. parallel, for,...) (in realta' in alcuni casi si hanno delle scorciatoie p.es.: parallel for sulla stessa riga e' valido)
- dopo il nome della direttiva si possono aggiungere delle clausole (p.es. shared (i) identifica che la variabile i e' shared)
- ogni direttiva si applica al piu' ad un un blocco strutturato; in un blocco strutturato c'e' un solo ingresso e una sola uscita, p.es. non si puo' entrare/uscire con i goto! (ma si puo' uscire con un exit () in C o stop per il FORTRAN).
- se la direttiva e' lunga si puo' andare a capo con \ e continuare la direttiva.

Esempio della struttura di una direttiva:

Alla fine della direttiva si deve andare a canolillilli (senza "·" in C)



Alcune routine (funzioni) a runtime di openMP



Alcune utili funzioni definite da openMP (queste non vanno messe dopo un #pragma):

- int omp get num threads (); numero di thread nel team (equivalente alla size di MPI nella regione parallela)
- int omp_get_thread_num(); la funzione restituisce l'id del thread chiamante (sotto forma di int) (equivalente del rank per i processi di MPI),per esempio: mioID=omp_get_thread_num();
- double omp get wtime(); wall time, per esempio: t1 = omp get wtime();
- void omp_set_num_threads(); definisce il numero di thread nei successivi costrutti paralleli (a meno che, nel frattempo, intervengano altre specificazioni sul numero di thread).
- get_num_procs(); trova il numero di CPU presente nella macchina
- int omp_in_parallel (), restituisce un valore intero che e' 0 se non siamo in una regione parallela attiva. Restituisce invece 1 se viene chiamato dall'interno di una regione parallela attiva.

Quanti thread?



Ci sono vari modi di definire il numero di thread in un blocco parallelo, per esempio:

```
omp_set_num_threads(4); // <= si definisce il numero prima del blocco
//... altro codice
#pragma omp parallel
{
   int ID = omp_get_thread_num();
   printf("Io sono: %d", ID);
}</pre>
```

Oppure si puo' definire al momento della creazione della direttiva:

```
int vaiParallelo = 0;
#pragma omp parallel if (vaiParallelo == 1) num_threads( 8) shared (var_b) default ( none)
{    // per fare si che num_threads( 8) venga preso, meglio mettere vaiParallelo=1;
    int ID = omp_get_thread_num();
    printf("Io sono: %d", ID);
```

In ordine di importanza il numero di thread e' determinato nel seguente modo (piu' lontano = meno importante) :

- valutazione della clausola if con di seguito il valore all'interno della clausola num_threads()
- Utilizzo della funzione omp_set_num_threads() (prima del blocco parallelo)
- il valore della variabile d'ambiente OMP_NUM_THREAD (settata precedentemente)
- default della implementazione (numero di core di un nodo)

I thread sono identificati da un id che va da 0 (per il Master) a N-1 (N =numero thread della regione parallela).

Come comunicano i thread? Data sharing



Quando c'e' una sessione parallela bisogna definire come vengono gestite le risorse (le variabili, gli array...). In particolare e' importante sapere quale thread ha accesso a **quale** risorsa, qui indichiamo alcune delle clausole principali:

- private (i) ogni thread ha la propria versione privata della variabile (non c'e' race condition), indipendente da tutte le altre copie. La variabile e' inizializzata secondo l'inizializzazione standard (come nel main). Domanda: puo' essere un puntatore?
- shared (v, u) indica che gli oggetti v e u possono essere usati da tutti i thread all'interno della regione parallela (puo' causare race condition). Gli oggetti sono condivisi con il resto del codice.
- firstprivate(i) e' identico a private ma il valore di i e' inizializzato con l'ultimo valore posseduto prima del
 costrutto parallelo (ergo del master thread).
- default (shared) significa che le variabili esterne diventano shared nel costrutto parallelo (e' il default per un costrutto parallel).
- default (private) indica che tutte le variabili, array sono private all'interno del costrutto
- Esiste anche default (none): richiede di specificare per ogni variabile il suo attributo di data sharing: e' una buona pratica di programmazione!
- lastprivate (j) all'uscita dalla regione parallela (JOIN) la variabile viene aggiornata per il master thread (che
 continua ad esistere) con l'ultimo valore della regione parallela (spiegata piu' approfonditamente nel seguito).

Attenzione

- le variabili definite prima del costrutto parallel sono automaticamente shared
- Le variabili definite all'interno del costrutto parallel sono automaticamente private

Attenzione

costrutti paralleli differenti (p.es. #pragma omp task definiscono in modo diverso dal costrutto parallel quali sono le caratteristiche di default delle variabili all'interno della loro regione.

Esempio: shared e private di default



Cosa scrive a video il computer?

```
#include <stdio.h>
#include <omp.h>
int main() {
  int a=5; // a viene definita PRIMA del costrutto parallel, nel costrutto parallelo e' shared
   #pragma omp parallel num_threads(3)
     int id: // id e' definita dentro il costrutto e' PRIVATA di default
     id = omp get thread num();
     printf("thread: %d, a=%d\n", id, a);
```

thread: 0. a=5thread: 2. a=5 thread: 1. a=5

Se invece avessi inserito:

```
#pragma omp parallel num threads(3) private(a)
```

il risultato sarebbe stato:

```
thread: 1. a=0
thread: 2, a=0
thread: 0, a=0
```

Attenzione: nelle versioni piu' recenti di openMP le variabili private sono inizializzate automaticamente come lo sarbbero nel main. Nelle versioni piu' vecchie invece non sono inizializzate! Fidarsi dell'inizializzazione di una clausola private e' pericoloso! #include <stdio.h>

esempio: firstprivate



Cosa scrive a video questo codice?

```
#include <omp.h>
int main()
{
    int b=5;
    printf("Prima del costrutto parallelo b=%d\n", b);
    #pragma omp parallel num_threads(3) firstprivate(b)
    {
        int id;
        id = omp_get_thread_num();
        b = b+id;
        printf("thread: %d, b=%d\n", id, b);
    }
    printf("Dopo il costrutto parallelo b=%d\n", b);
}
Soluzione:
```

```
Prima del costrutto parallelo b=5
thread: 0, b=5
thread: 2, b=7
thread: 1, b=6
Dopo il costrutto parallelo b=5
```

problemi di default...



Trovare il problema:

```
#include <stdio.h>
#include <omp.h>

int main(){
   int a=5;
   #pragma omp parallel num_threads(3) default(none)
   {
      printf("thread: %d, a=%d\n", omp_get_thread_num(), a);
   }
}
```

Soluzione:

- La variabile a e' dichiarata e definita prima della regione parallela.
- Se non ci fosse un default (none) nella regione parallela verrebbe trattata come shared.
- In questo caso invece la clausola default (none) crea problemi al compilatore: non sa come trattare a!
- Per risolvere il problema basta aggiungere una clausola tipo shared (a), private (a)... per esempio:

```
#pragma omp parallel num threads(3) default(none) private(a)
```

l'uso di default (none) e' una buona pratica di programmazione, perche' ci obbliga a dichiarare esplicitamente il
possesso delle variaibili

Ш

Cominciamo Bene...

Un esempio di codice volenteroso ma problematico:

```
#include<comp.h>
#include<stdio.h>
int main()
{
   int i=0, j=0, imax=10, tanto=1000000;
   omp_set_num_threads(imax);
   #pragma omp parallel private (j)
   {
      for (j=0;j<tanto; j++) // questo serve per aumentare i problemi...
      i = i +1;
   }
   printf("teorica= %d, somma con i thread= %d \n", imax*tanto, i);
}</pre>
```

Sto utilizzando i thread, ma come? Problemi

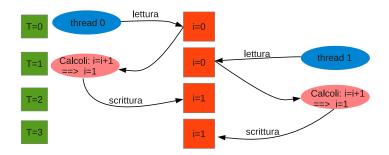
- Tutti i thread cercano di aggiornare la varaibile i.
- la variabile i e' condivisa da tutti i thread: l'aggiornamento genera una race condition
- Attenzione di solito la race condition non sussiste ... se eseguo in locale con una sola cpu, dato che in questo modo i
 thread vengono simulati e quindi eseguono uno dopo l'altro! Il ciclo su j e' stato messo apposta per aumentare la
 probabilita' che succeda.
- Occhio quindi un codice che funziona perfettamente su una macchina virtuale potrebbe essere completamente bacato!

visualizziamo una Race Condition (datarace)



18 / 54





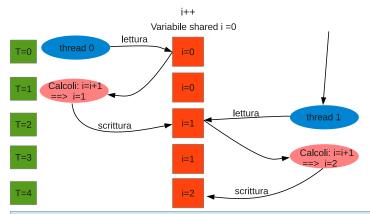
Alla fine il valore della varibaile i viene aggiornato dal thread 1, che **NON** tiene conto dei nuovi calcoli fatti dal thread 0.

Paolo Avogadro (DISCo) Milano 2019

visualizziamo una Race Condition 2



19 / 54



Fortunatamente, questa volta il thread 1 legge la variabile i **DOPO** che il thread 0 ha aggiornato il valore. Il risultato dipende da quando i thread accedono alla variabile

Paolo Avogadro (DISCo) Milano 2019

Un primo esercizio (con sincronizzazione manuale)



- Problema: prendere tutti i numeri da 1 a N e sommarli usando una ragione parallela.
- si definisca il numero di thread tramite il comando omp_set_num_threads()
- si ottenga l'id del singolo thread tramite omp_get_thread_num()
- il blocco parallelo necessita di #pragma omp parallel
- dato che ci sono vari thread e la somma e' associativa, ogni thread eseguira' un pezzo della somma e lo mettera' in un
 ingresso di un array condiviso (shared), chiamato arr_sum con un ingresso per ogni thread della regione parallela
- alla fine dopo la regione parallela il master thread fa la somma dei vari ingressi dell'array.

Un primo esercizio (lo scheletro del codice)

B I C O C C

Sommiamo i primi numeri da 1 a N. Usare omp_set_num_threads () per decidere il numero dei thread, omp_get_thread_num() per conoscere il proprio id, e #pragma omp parallel per iniziare il blocco. La parte "difficile" e': suddividere il compito tra i thread correttamente!

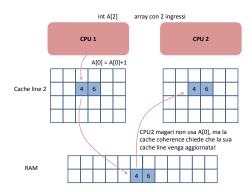
```
#include < omp.h > // una somma inutilmente difficile dei numeri da 1 a N
#include<stdio.h>
static long N = 1000:
                                     // numero di punti da sommare
void main ()
int i, sum=0;
int numThreads = N / 10:
                                    // numero di thread usato
//******* diciamo qui ad openMP che vogliamo numThreads
int arr sum[numThreads];
                                      // array con somme parziali
//***** facciamo partire il blocco parallelo
       int par , arr;
                          // partenza e arrivo
//****** chiediamo a openMP l'id del chiamante, chiamiamolo "me"
//******* calcoliamo quanti punti sono calcolati da ogni thread
       int local sum=0
                                      // azzeriamo la somma locale da calcolare
//****** calcoliamo il punto di partenza della somma (funzione dell'id)
//******** calcoliamo il punto di arrivo della somma (funzione dell'id)
       for (i= par; i< arr; i++) {</pre>
               local sum = local sum + i; // somma dei valori da "par" a "arr"
//****** mettiamo la somma locale in un array globale
 for (i=0;i<numThreads: i++) {sum += arr sum[i]:}</pre>
 printf("Somma= %d, teorica %d\n", sum, N*(N+1)/2);
```

Un primo esercizio: false sharing



Nell'esercizio precedente possono esservi problemi di cosiddetto: false sharing

- Supponiamo nel computer in cui gira il codice ci sia cache coherence tra i vari core, ognuno dei quali ha una propria cache
- Se il codice e' stato scritto a dovere, i vari thread "riempiono" indici diversi dello stesso array
- che, con buona probabilita' sara' su una singola cache line quindi il computer dovra' riscrivere la cache per tutti i thread ogni volta che un ingresso dell'array viene aggiornato (passando per la memoria)!



Paolo Avogadro (DISCo) Milano 2019 23 / 54

Come evitare il false sharing?

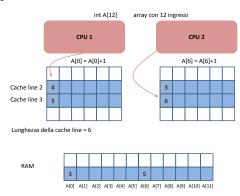


Nella diapositiva precedente abbiamo visto un caso in cui:

- due core accedono e modificano un solo array.
- Il primo core lavora solo con il primo ingresso dell'array
- il secondo core lavora solo con il secondo ingresso dell'array

Per questo motivo se non si sta attenti ci si aspetta che non si "calpestino i piedi"! sfortunatamente il sistema ha la proprieta' di cache coherence, e quindi non appena uno dei due core scrive su una cache line e l'altro deve accedere alla stessa cache line, il sistema deve aggiornare la cache del secondo core, rallentando il processo.

Consiglio Per evitare questo potrebbe essere possibile scegliere di creare un array, piu' grande, in modo che i due ingressi su cui lavorano i due core, appartengano a due cache line differenti!



Alcuni costrutti di sincronizzazione: critical



#pragma omp critical

specifica che nel blocco che la segue puo' entrare solo un thread alla volta

- rallenta il sistema dato che serializza
- ci sono degli overhead dovuti al fatto di fare entrare e uscire un singolo thread, per esempio l'addizione diventa circa 200
 volte piu' lenta rispetto alla controparte senza critical.
- aiuta ad evitare le datarace/race condition
- si puo' dare un nome alla sessione critical, per esempio: #pragma omp critical (PrimaSessione)
- se ci sono piu' critical senza nome (unnamed), quando un thread entra in uno di questi blocchi, li chiude tutti a chiave (nessun processo puo' entrare negli altri blocchi!), questo puo' essere superato se si danno i nomi alle sessioni

altri costrutti di sincronizzazione: atomic e barrier



#pragma omp atomic permette di fare aggiornare una variabile ad un thread alla volta.

- c'e' (molto) meno overhead rispetto alle critical
- assicura la serializzazione di una singola operazione. In pratica il primo thread che arriva, e trova una operazione su
 una variabile, dice a tutti gli altri: adesso io ho il controllo della variabile!
- l'addizione e' circa 25 volte piu' lenta rispetto ad un sistema non critical
- le funzioni che si possono usare sono: +, *, -, /, &,' |, <<, >> (occhio che una scrittura tipo i=i+miafunc() e' valida, in quanto all'oggetto di cui vogliamo fare l'update ho fatto solo una somma)

Esercizio: Scrivere un codice che aggiorna la variabile conto per ogni thread in modo da avere il numero totale di thread della regione parallela:

Nel caso in cui si necessiti che tutti i thread abbiano finito di eseguire il proprio compito prima di continuare l'esecuzione si mette una barriera:

#pragma omp barrier

(qui non c'e' problema perche' alla fine di una regione parallel, c'e' una barriera implicita)

Altri costrutti di sincronizzazione: master, single e ordered



#pragma omp master fa eseguire il blocco di seguito solo al master thread.

- gli altri thread saltano il costrutto master
- NON c'e' nessuna barriera implicita ne' ingresso ne' in uscita (quindi gli altri thread semplicemente ignorano il costrutto!
- la mancanza di barriere e' pericolosa

Il costrutto single assomiglia al master, ma:

- non e' eseguito dal master, qualunque (singolo) thread potrebbe essere l'esecutore
- esiste una barriera implicita in uscita (tutti i thread attendono che il costrutto single venga eseguito prima di continuare)

il costrutto ordered fa eseguire in ordine i vari thread come se fossero in un loop seriale (in qualche modo sospende il costrutto parallelo). Altrimenti se ci fosse una parte che va eseguita in serie dovrei de facto chiudere tutto il costrutto parallelo e perdere le informazioni private di ogni thread.

Riduzione



anche in openMP e' possibile definire delle operazioni di riduzione con la seguente sintassi:

#pragma omp reduction(operazione:nomevariabile)

- dove le operazioni disponibili sono: +, -, *, &, |, &&, ||
- Attenzione si possono definire opportunamente delle funzioni da usare nella riduzione, noi non lo faremo). Una funzione
 di riduzione deve poter prendere 2 valori e restituirne 1, e deve godere della proprieta' associativa (vedi diapositiva
 successiva).

Esercizio: scrivere un codice che usi la somma come operazione di riduzione per contare il numero di thread all'interno della regione parallela:

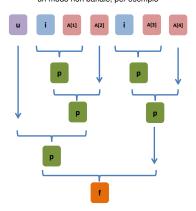
```
#include <omp.h>
#include <stdio.h>
int main ()
{
   int somma=0;

   // introduco la regione parallela con clausola di riduzione per "somma"
{
   // aggiungo 1 a "somma" per ogni thread della regione parallela
}
printf("Numero di thread presenti = %f\n", somma);
}
```

Occhio alla riduzione



Attenzione: tutte le operazioni di riduzione hanno come default un valore, che in generale (ma non sempre) sara' l'elemento neutro dell'operazione (per esempio per la somma lo 0, per il prodotto l'1, etc...). Questo perche' la riduzione viene effettuata in un modo non banale, per esempio



- u= valore di inizializzazione assegnato dal programmatore alla variabile da ridurre
- i= valore di inizializzazione di default dell'operazione
- A[1],A[2],A[3],A[4] ... sono i valori che ottengono i thread, il thread(1), il thread(2), etc...
- f= valore finale della riduzione

Work-sharing



- All'interno di una regione parallela, le direttive di tipo work-sharing consentono ai thread (o ai task, che vedremo piu' avanti) di gestire il modo di lavorare concorrente.
- i costrutti work-sharing NON creano nuovi thread.
- un costrutto work-sharing deve essere incluso in una regione parallela per poter eseguire in parallelo... (sembra ovvio ma alle volte si dimentica)
- i costrutti work-sharing devono essere chiamati da tutti i thread o da nessuno (assomigliano in questo a delle collective communications di MPI)
- le regioni di tipo worksharing, hanno una barriera implicita alla fine del costrutto, ovvero tutti i thread devono avere completato il proprio lavoro, prima che si possa passare oltre il costrutto stesso.

Due costrutti work-sharing principali per il C:

- for periloop
- sections peritask

La direttiva di Work-sharing: for



(in FORTRAN e' sostituita dalla direttiva do)

E' una direttiva utilissima: fa suddividere automaticamente un ciclo for tra i thread della regione parallela, de facto rendendo la varibile del loop privata e suddivisa tra thread.

- questa direttiva parallelizza automaticamente il ciclo for rendendo privata la variabile del ciclo per ogni thread.
- onon ci devono essere dipendenze all'interno dei loop, tipo a [i] =a [i-1] +3
- Se ho un ciclo da 1 a 100 e ci sono 10 thread, esistono modi differenti per "suddividere" (worksharing) il lavoro

Esempio (con dubbi) implementare ciclo for:

```
#include <omp.h>
#include <stdio.h>
#include <stdlib.h>
void main()
   int i, N=20;
   int *a:
   a = (int*) malloc(N*sizeof(int));
   // inizio costrutto parallelo con 5 thread
   // inserire un comando openMP che per il ciclo
   for (i=0; i<N; i++)</pre>
         a[i]=i:
                                       // ogni thread deve riempire un ingresso diverso
        fine costrutto parallelo
   for (i=0;i<N;i++)
                                     // controllo
   printf("%d\n", a[i]);
```

Non tutti i "for" sono uguali...



Non tutti i cicli for possono essere parallelizzati. Questo e' intuitivo, in quanto il computer deve essere in grado di suddividere il lavoro tra i vari thread e quindi deve avere ben chiaro l'ambito della variabile di loop, ovvero

for (inizializzazione; test; incremento)

- inizializzazione e' del tipo, per esempio: i=0, i=37, ...
- test, se il test e' vero, il loop continua. In pratica e' un vincolo entro cui si muove la variabile i. In un loop generico, basta che la condizione testata sia vera e si passa all' incremento. Pero' ci sono delle condizioni per cui e' difficile per il compilatore definire a priori quali valori puo' assumere la variabile i. Per esempio una condizione i! = 45 puo' essere difficile da raggiungere (magari i non vale mai 45...). Quindi le condizioni di test devono essere delle semplici:
- per questo motivo anche l'incremento deve essere semplice: la variabile puo' essere solo incrementata (o diminuita) di quantità' costanti! (i++, i=i+3, --i,...)

Con queste condizioni, il compilatore trova facilmente quanti \pm diversi tra loro ci sono e puo' decidere come suddividerli tra i vari thread.

Esempio di lastprivate: chi e' l'ultimo?



- Attenzione: una clausola lastprivate non puo' essere messa su un costrutto parallel qualsiasi: deve esserci un modo per definire qual'e' l'ultimo thread...
- Per ultimo non si intende (necessariamente) dal punto di vista temporale, ma ultimo secondo un univoco ordine logico/sintattico. Nel caso di un ciclo for il thread che lavora con gli ultimi indici e' l'ultimo. Quindi per un costrutto for e per le sections (che vedremo poi) si possono definire variabili lastprivate.

- Sebbene il thread 0 esegua per ultimo dal punto di vista temporale (per colpa dello sleep (2);)
- la variabile stampata e' quella del thread 3 ...
- ...perche' openMP, nel ciclo for, gli assegna l'**ultimo** valore dell'indice del ciclo (i=6).

for collapse



Nel caso in cui ci siano dei loop che sianno innestati perfettamente, e' possibile usare questa clausola aggiuntiva, in questo modo:

- il compilatore crea un unico loop e poi lo parallelizza
- non c'e' bisogno di scrivere 2 direttive #pragma omp for, una per ogni ciclo

```
# pragma omp parallel for collapse (2)
{
    for (i=1; i<10; i++)
    {
        for (j=1, j<10; j++)
        {
             somma = somma +i;
        }
    }
}</pre>
```

Come viene suddiviso il lavoro in un for (worksharing)



- clausola static: lavoro alloccato e assegnato all'inizio del loop
- clausola dynamic: il sistema decide come e quando assegnare un lavoro ad thread, non appena il thread ha eseguito e
 diventa idle, un nuovo compito puo' essere assegnato

openMP Scheduling:

- schedule(static [, chunksize])
- schedule(dvnamic[, chunksize])

Per esempio:

```
#pragma omp parallel for default(none), shared(chunksize) schedule(static,chunksize)
for( int index = 0; index < 12; index++)</pre>
```

Bell'esempio:http://jakascorner.com/blog/2016/06/omp-for-scheduling.html Prendiamo un loop con 64 iterazioni (i=0..... 63)

```
schedule(static)
th1 **********
th2
                   ***********
th2
                                   **********
t h 4
schedule(static,4)
th1 ****
                   ****
                                                   ****
th2
th3
t h4
schedule(static,8)
th1 ******
th2
                                           ******
th3
                   ******
                                                   *****
t h 4
```

Costrutto Parallel: variabili interne



Un buon motivo per cui ha senso la clausola private, all'interno di un parallel statement, e' che con openMP si vorrebbe poter aggiungere solo degli statement di tipo pragna SENZA cambiare la struttura del codice (se stiamo cercando di parallelizzare un codice seriale). Proviamo a vedere come si puo' modificare il codice qui sotto senza la clausola private:

L'unico modo (in assenza di private clause) richiede di modificare la forma del codice, per esempio:

Entrambi i codici sono validi, ma nel primo caso ho semplciemente dovuto inserire una riga di codice (eventualmente ignorabile), nel secondo caso ho cambiato la struttura!

Esercizio: π *in modo poco elegante*



```
Un codice che calcola \pi, usando il seguente risultato \int_{-\infty}^{+\infty} \frac{1}{1+x^2} dx = \pi
```

```
#include<omp.h> // una versione di Pi greco con worksharing "MANUALE"
#include<stdio.h>
static long num steps = 100000;  // numero di punti integrale
double step;
void main ()
       int i, tot=100; double x, pi, sum = 0.0;
       omp_set_num_threads(tot);  // def num thread
       step = 40000.0/(double) num steps; // grandezza step
       #pragma omp parallel private(x,i)
                    // partenza e arrivo
       int par , arr;
       int me = omp_get_thread_num(); // numero identificativo del thread
       double local sum=0;
       par = me * stxt;
                     // indice di partenza
       arr = par + stxt;
                              // indice di arrivo
       for (i= par; i< arr; i++) {</pre>
         x = (i+0.5)*step;
                          // punto integrazione
         local sum = local sum + 2.0/(1.0+x*x);
        arr_sum[me] = local_sum; // arrav locale
       for (i=0;i<tot; i++) {sum += arr sum[i];}</pre>
       pi = step * sum;
    printf("Pi Greco= %f\n", pi);
```

Esercizio: π



Qui proviamo ad ottenere lo stesso risultato ma:

- 1 usare come scheletro l'esercizio di somma della lezione precedente
- invece che suddividere la somma "manualmente" usare il costrutto #pragma omp for
- 3 alla fine usare l'operazione di riduzione "somma"

π con il costrutto for



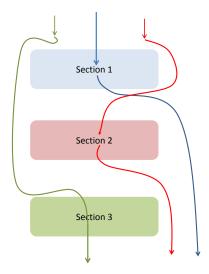
```
#include<omp.h> //
#include<stdio.h>
double step;
void main ()
      int i, tot=100; double x, pi, sum = 0.0;
      omp set num threads(tot); // def num thread
      step = 40000.0/(double) num_steps; // grandezza step
      //===== costrutto di openMP
      int me = omp_get_thread_num();  // numero identificativo del thread
      double local sum=0;
//===== costrutto di openMP
      for (i= 0; i< num_steps; i++) {</pre>
         x = (i+0.5)*step; // punto integrazione
         local sum = local sum + 2.0/(1.0+x*x);
         arr sum[me] = local sum; // arrav locale
      sum = 0 :
//===== qui starebbe bene una riduzione
      for (i=0;i<tot; i++) {</pre>
                        printf(" %f\n", step*arr sum[i]);
                       sum += arr sum[i]:
      pi = step * sum;
   printf("Pi Greco= %f\n", pi);
```

Worksharing: Sections



La direttiva sections divide esplicitamente il lavoro tra i thread, (anche in questo caso puo' essere utile utilizzare la clausola nowait per evitare che ci sia una barriera implicita alla fine di una direttiva sections).

- il primo comando openMP inizializza le sezioni
- il secondo e il terzo comando openMP esplicitano l'inizio di una sezione
- alla fine delle sections c'e' una barriera implicita
- supponiamo che ci siano 4 thread nella regione parallela, ma solo 2 sezioni, cosa succede? solo 2 thread lavoreranno, gli altri saranno inattivi!



Domanda: Cosa succede se ci sono piu' "sections" che thread? Risposta: Un thread eseguira' piu' di una section.

Task



In openMP 3 (e migliorato in 4.0) e' stato introdotto il costrutto **Task**. Il nome e' intuitivo: si crea un compito che dovra' poi essere eseguito. L'idea e' quella che i compiti possano necessitare un'esecuzione non semplicemente gestibile con gli altri costrutti. Per esempio se si deve lavorare con delle funzioni ricorsive o con dei "linked set".

Un task si compone di:

- codice da eseguire
- Data environment (ovvero degli argomenti di input e di outoput)
- da chi il task viene eseguito (un thread)
- si deve definire **esplicitamente** cosa e' un task (con il task construct)
- un task puo' essere eseguito immediatamente (appena costruito) (undeferred) o posticipato (deferred) (messo nel task pool ed eseguito poi)
- a runtime viene deciso se il momento di esecuzione del task e' deferred o undeferred
- i task possono essere innestati (ricorsivi)

N.B. Anche prima di openMP 3.0 i task esistevano, pero' venivano assegnati ai thread automaticamente.

Task 2



il costrutto task che funziona in questo modo:

- un thread arriva sul costrutto task, tutto quello che trova all'interno del costrutto diventera' un compito (o piu' d'uno) che viene messo nel task pool (oppure con una decisione a runtime, il task viene eseguito subito)
- il thread continua nella sua parallel region (per esempio, se incontra nuovamente costrutti task, ne crea di nuovi)
 il thread accidente alla fina della sua parallel region (per esempio, se incontra nuovamente costrutti task, ne crea di nuovi)
- il thread, arrivato alla fine della parallel region, comincia a pescare dai task e li esegue; piu' in generale i task cominciano ad essere eseguiti non appena i thread incontrano una barriera (esplicita o implicita).
- un task puo' essere tied ad un thread o untied. Nel primo caso se un thread comincia un task solo quel thread puo' continuarlo. Nel secondo caso, un thread puo' cominciare un task, interrompere il lavoro (con opportune clausole o direttive, o anche perche' l'esecuzione del task richiede un altro task, per esempio se stiamo usando task ricorsivi) e magari un altro thread finisce il lavoro. tied e untied sono delle clausole che possono essere usate sulla direttiva task

I **task** possono essere ricorsivi e sono eseguiti secondo la execution tree (prima il genitore, poi il figlio etc...)

L'utente identifica i task e poi lascia che sia il computer ad scegliere l'ordine di esecuzione: parallelismo irregolare

Generare Task



Per generare i task posso per esempio usare un codice del tipo:

- quanti task verranno generati?
- quando verranno eseguiti?
- da chi verranno eseguiti?
- se sto generando una lista troppo grande di task, l'implementazione puo' decidere di passare dalla generazione alla esecuzione dei task stessi
- pericolo se, prima di avere finito di generare tutti i task, il thread che genera i task si mette ad eseguire un task molto lungo... si arriva in una condizione di starvation (i task hanno fame...). Nuovi task non vengono generati, e ci sono dei thread che aspettano!

Task data scoping



Ricordiamo che la generazione ed esecuzione di un task non coincidono temporalmente.

- Se una variabile e' shared in un costrutto task il suo valore (referenza) all'interno del costrutto e' riferito al momento in cui il task e' stato generato.
- le referenze ad una variabile private all'interno del costrutto sono rispetto ad un nuovo valore non inizializzato e creato al momento dell'esecuzine del task.
- le referenze una variabile firstprivate, all'interno del costrutto, sono rispetto ad un uovo oggetto, creato al momento dell'esecuzione con valore di inizializzazione uguale a quello della variabile al momento di creazione del task.
- In un costrutto di tipo task, se non e' presente nessuna clausola di tipo default, allora una variabile che e' shared, nel piu' interno dei costrutti esterni (al task), continua ad essere shared.
- in un costrutto task, se non c'e' nessuna clausola default, una variabile i cui attributi di data sharing non siano determinati dal punto precendente (ovvero shared), e' firstprivate.

(Per esempio se un costrutto task e' incluso in un costrutto parallelo, allora tutte le variabili che sono shared rimangono shared anche nel task, altrimenti vengono trasformate in firstprivate)

Consiglio: per evitare confusione sarebbe meglio che si definisse esplicitamente come sono le variabili all'interno del task, tramite l'utilizzo di calusole tipo: private, lastprivate, etc... (usare sempre default (none) non provoca crampi alle dita!)

Esempi coi task

```
BICOCC
```

```
int a=1;
int b=2;
# pragma omp parallel firstprivate (b)

{
    int c=4;
# pragma omp task shared(c)
    {
        int d = 5;
        eseguiFunzione(e,b); // esempio di funzione da eseguire
      }
}
```

- a shared (non essendoci clausole che la riguardano rimane shared in tutto il codice)
- b firstprivate nella regione parallela e resta firstprivate nel task. Esiste fuori dalla regione parallela.
- o private nella regione parallela e diventa shared nel task. Non esiste fuori dalla regione parallela.
- d private per ogni task. Non esiste fuori dal task.

Variabili e task: esempio

```
BICOCC
```

```
#include <stdio.h>
#include <omp.h>
void main()
   int tot=6:
   int i, j;
   #pragma omp parallel num_threads(tot)
      int id = omp_get_thread_num();
                                              // id e' private, per ogni thread
                                               // ne entra solo 1
      #pragma omp single
         for (i=0; i<3;i++)</pre>
                                               // costruisce 3 task
            #pragma omp task
             for (j=0; j<1000000; j++);  // task deferred</pre>
             printf("Sono il thread=%d\n", id);
```

Attenzione: Cosa scrive a video?

- id e' definito dentro il costrutto parallel, quindi e' privato per ogni thread
- quando entra nel costrutto task diventa firstprivate
- le variabili del task vengono "create" dal thread che e' entrato nel single che quindi definisce il valore di id!

Task...wait!



Una delle caratteristiche del costrutto task e' quello di poter agevolare la scrittura di codici che abbiano delle parti ricorsive. Per questo motivo e' stata introdotto un utilissimo comando:

```
#pragma omp taskwait
```

Questa direttiva specifica che il task deve aspettare il completamento di tutti i task figli generati dall'inizio del task corrente occhio che vale per i figli non tutti i discendenti!

```
#pragma omp taskgroup
```

fa bloccare il thread finche' tutti i task discendenti all'interno della regione sono completi.

Costuire un codice per calcolare il fattoriale



```
    creare una funzione fattoriale
```

```
    se i < 2 ⇒ fat(i) = i (se i=0 fat(i)=1)</li>
    costruire un task fat(i-1)
```

```
#include <stdio.h>
#include <omp.h>
int fat (int n)
 int i, j;
 if (n<1) return 1;
 if(n<2)
   return n:
 else
     i=fat(n-1);
// -----
     return i*n;
int main()
 int n = 14;
 omp set num threads (100);
// ====== omp ======
  ----- omp
   printf ("fat(%d) = %d\n", n, fat(n));
```

openMP fine



- Introdotta l'idea di openMP: team di tread con fork e join
- introdotto come comunicano i thread: data sharing
- definite le clausole principali per il data sharing (shared, private, firstprivate, ...)
- introdotti i costrutti di worksharing, sections e soprattutto i task.

Compito Provare ad impostare un codice che sfrutti openMP per calcolare il prodotto tra matrici. Domanda: Cannon e' un buon algoritmo per la moltiplicazione tra matrici per openMP? perche'?